

基于特征地图的移动机器人全局定位 与自主泊位方法

陈凤东¹, 洪炳镕²

(1 哈尔滨工业大学电气工程与自动化学院, 黑龙江省哈尔滨 150001;

2 哈尔滨工业大学计算机科学与技术学院, 黑龙江省哈尔滨 150001)

摘 要: 提出一种新的移动机器人全局定位与自主泊位方法. 该方法分为两阶段: 离线阶段, 采用 SIFT(Scale Invariant Feature Transform)算法并提出一种基于 DD-BBF(Double Direction Best Bin First)的特征匹配方法实现视觉特征三维重建; 将进化策略应用于 Rao-Blackwellized 粒子滤波器, 并结合自适应重采样, 实现了移动机器人同时定位和特征地图创建. 在线阶段, 采用基于 HMM(Hidden Markov Model)的方法实现全局泊位位置识别; 采用 RANSAC 算法实现全局度量定位; 提出极点伺服控制方法, 实现机器人精确自主泊位. 在室内环境下的实验结果证实了该方法的优良性能.

关键词: 移动机器人; 导航; 粒子滤波; 视觉伺服; 极线几何

中图分类号: TP24 **文献标识码:** A **文章编号:** 0372-2112(2010)06-1256-06

A Global Localization and Self-Docking Method for Mobile Robot Based on Feature Map

CHEN Feng-dong¹, HONG Bing-rong²

(1 School of Electrical Engineering and Automation, Harbin Institute of Technology, Harbin, Heilongjiang 150001, China;

2 School of Computer Science and Technology, Harbin Institute of Technology, Harbin, Heilongjiang 150001, China)

Abstract: A global localization and self-docking method for mobile robot is presented. The method is composed of two stages; during the off-line stage, SIFT (scale invariant feature transform) algorithm is used and a DD-BBF (double direction best bin first) matching method is presented to implement the 3-D reconstruction of vision features; an ES (evolution strategy) and adaptive re-sampling scheme were applied in RBPF (Rao-Blackwellized particle filter) to implement the mobile robot SLAM (simultaneous localization and mapping). In the on-line stage, the global docking station is recognized through HMM (Hidden Markov Model) based method, the global metric pose and location of the robot are estimated by a RANSAC algorithm; and then an epipole servoing method is presented to dock the robot precisely. Experiment results carried out with a real robot in an indoor environment show the superior performance of the proposed method.

Key words: mobile robot; navigation; particle filter; visual servoing; epipolar geometry

1 引言

移动机器人定位与泊位是机器人领域中两个关联紧密的基本问题. 在许多应用中, 机器人需要先确定当前位姿, 然后泊位到特定的位置和方向, 才能实现指定的任务, 如自主充电^[1]. 本文研究室内环境下基于单目视觉的移动机器人全局定位与泊位问题. 全局定位要求机器人能够在初始位姿不确定的情况下, 通过有噪声的感知信息估计位姿, 解决全局定位的主要方法包括: 卡尔曼滤波器^[2], 马尔可夫定位和粒子滤波器^[3]方法等,

其中粒子滤波器方法取得较大成功, 但传统粒子滤波器方法有许多局限性^[4]: 一是如果在正确状态附近没有足够的粒子会导致滤波器发散; 二是粒子经常快速收敛而得到非最优结果. 怎样提高粒子滤波器准确性和有效性、防止粒子发散和退化, 同时兼顾粒子数增加带来的计算负担重的问题是研究者一直关注的问题. 针对上述问题, 本文采用先创建环境地图, 再进行基于 RANSAC 鲁棒估计的全局定位方法, 有效解决了全局定位问题; 其中将进化策略应用于 Rao-Blackwellized^[5] 粒子滤波器, 并结合自适应重采样, 有效解决了计算负担重的问题. 又可以防止

粒子退化和早熟. 对于自主泊位问题, 已有方法中航位推算法 (dead reckoning) 具有误差积累问题, 相比之下, 视觉伺服方法通过当前图像信息进行迭代控制, 可避免误差积累问题. 但视觉伺服方法通常要求目标在视场内, 这限制了机器人的运动控制. 然而由于其具有定位精度高的优点, 许多研究者积极寻求解决的方法: Blanc^[6] 采集沿路天花板关键图像, 应用单应约束控制机器人路线. 这扩展了视场, 但如果机器人改变出发点, 该方法可能会失效. Gian^[7] 使用全维视觉实现机器人泊位, 但畸变的图像可影响定位精度. Sunhyo^[8] 设计一种模糊控制器集成基于位置和基于图像两种视觉伺服方法, 使用前者优化路径, 后者使目标总在视场内. 该方法可有效保持目标不出视场, 但为了保持目标不出视场, 限制了机器人的路径范围. 针对这个问题, 本文采用基于环境地图的全局和相对定位解决视场有限的问题. 采用极点伺服方法完成末段精确泊位. 本文的贡献在于: (1) 提出一种基于 SIFT^[9] 特征地图的全局定位方法; (2) 在具有自适应采样的 RBPf 中引入进化策略, 有效解决了 RBPf 创建大地图时的计算和存储负担太重的问题, 又防止了粒子退化和早熟; (3) 提出一种基于 DD-BBF 的特征匹配算法, 有效解决了数据匹配问题; (4) 提出一种鲁棒的位置识别算法, 可用于全局位置识别; (5) 提出一种极点伺服方法, 提高机器人泊位精度.

2 环境地图

环境地图由离线阶段创建. 采用改进的 RBPf 实现 SLAM, 通过把有度量信息的特征点 (路标) 关联到节点位置中, 实现环境地图. 地图中每个节点 i 对应一个位置 L_i , 位置对应一定空间区域. 每一个位置由一组视图 (views) 及其特征 $F = \{F_1, F_2, \dots, F_3\}$ 描述. 每一组视图有一个共同的参考基 B_i . 弧 rt_{ij} 是基之间的关系即 $rt_{ij} = rt(B_i, B_j) = (x_{ij}, z_{ij}, \theta_{ij})$, 由里程计初始估计得到, 通过概率方法进行修正.

2.1 改进的 RBPf

当机器人在未知的环境中运动时, 根据环境生成一系列路标, 定义每一个路标 n 为 θ_n . 机器人以已知的运动模型 $p(s_t | u_t, s_{t-1})$ 运动, s_t 代表机器人 t 时刻状态, $[t-1, t]$ 内的控制输入为 u_t . 当机器人运动时, 以观测模型 $p(z_t | s_t, \theta, n_t)$ 得到观测值 z_t , θ 是一系列路标, n_t 是 t 时刻观测到的路标的索引号. 基于 RBPf 的 SLAM 问题就是计算后验概率分布:

$$p(s^t, \theta_1, \dots, \theta_M | z^t, u^t, n^t) = p(s^t | z^t, u^t, n^t) \prod_{n=1}^M p(\theta_n | s^t, z^t, n^t) \quad (1)$$

其中 M 是到目前为止观测到的路标数目, s^t 代表 s_t ,

$\dots, s_t(z^t, u^t$ 与 s^t 类似). 本文对 RBPf 改进如下:

(I) 采样新位置: 根据当前观测, 使第 i 个新位姿 $s_t(i)$ 由混合提议分布得到:

$$q = \kappa p(s_t | z_t, \theta) + (1 - \kappa) p(s_t | s^{t-1(i)}, u_t) \quad (2)$$

其中 $s^{t-1(i)}$ 是第 i 粒子到 $t-1$ 时刻的位姿, κ 是尺度系数. $p(s_t | s^{t-1(i)}, u_t)$ 可直接从基于里程计的运动模型中得到. 对于 $p(s_t | z_t, \theta)$, 根据观测函数 $z_t = g(\theta_{n_t}, s_t)$ 和相应的地图 θ , 对 $p(s_t | z_t, \theta)$ 进行高斯近似:

$$p(s_t | z_t, \theta) = N(\mu, \Sigma)_{s_{1, \dots, N}}.$$

(II) 更新路标: 通过平均值 $\mu_{n, t-1}^{(i)}$ 和协方差 $\Sigma_{n, t-1}^{(i)}$ 更新路标的后验分布. 更新值加入到新采样位姿 $s_t(i)$ 的临时粒子集 Ψ_t . 更新取决于 t 时刻是否观测到路标 n . 如果 $n \neq n_t$, 路标后验保持不变; 如果 $n = n_t$, 更新如下:

$$p(\theta_{n_t} | s^{t(i)}, n^t, z^t) = \eta p(z_t | \theta_{n_t}, s_t^{(i)}, n_t) p(\theta_{n_t} | s^{t-1(i)}, n^{t-1}, z^{t-1}) \quad (3)$$

$$\sim N(z_t; g(\theta_{n_t}, s_t^{(i)}), R_t) \quad \sim N(\theta_{n_t}; \mu_{n_t, t-1}^{(i)}, \Sigma_{n_t, t-1}^{(i)})$$

$t-1$ 时刻的 $p(\theta_{n_t} | s^{t-1(i)}, z^{t-1}, n^{t-1})$ 采用包含 $\mu_{n_t, t-1}^{(i)}$ 和 $\Sigma_{n_t, t-1}^{(i)}$ 的高斯描述. 由于 t 时刻的估计也是高斯的, 需要得到 $g(\theta_{n_t}, s_t^{(i)})$ 的高斯近似: $g(\theta_{n_t}, s_t^{(i)}) \approx g(\mu_{(t-1), j}^{(i)}, s_t^{(i)}) + g'(\mu_{(t-1), j}^{(i)}, s_t^{(i)})(\theta_{n_t} - \mu_{(t-1), j}^{(i)})$, 在这

$$= z_t^{(i)} \quad = \hat{G}_t^{(i)}$$

种近似下, 新的平均值和协方差更新为:

$$K_t^{(i)} = \Sigma_{n_t, t-1}^{(i)} P_{z_{n_t}, t}^{(i)} (P_{z_{n_t}, t}^{(i)T} \Sigma_{n_t, t-1}^{(i)} P_{z_{n_t}, t}^{(i)} + R_t)^{-1} \\ \mu_{n_t, t}^{(i)} = \mu_{n_t, t-1}^{(i)} + K_t^{(i)} (z_t - \hat{z}_t^{(i)})^T \\ \Sigma_{n_t, t}^{(i)} = (I - K_t^{(i)} P_{z_{n_t}, t}^{(i)T}) \Sigma_{n_t, t-1}^{(i)} \quad (4)$$

(III) 自适应重采样: 重采样对 RBPf 性能产生很大影响, 不仅低权重粒子被高权重粒子所代替, 同时只允许有限必要的粒子近似后验. 因此当提议分布与后验分布相差较大时, 重新采样非常重要. 但重新采样也可能忽略某些权重较高粒子, 最坏时能导致滤波器发散. 为此定义一个有效值 $N_{eff} = 1 / \sum_{i=1}^n (w^{(i)})$ 来表示当前粒子集近似后验的好坏, 如果 $N_{eff} \leq n/2$ (n 是粒子数), 就进行重新采样, 否则不进行.

(IV) 引入进化策略: 上述重采样可能损耗粒子多样性. 因为重采样可能导致重复拷贝一部分甚至一个粒子, 这是严重的采样退化. 为使重采样引入的采样变化不影响近似计算的有效性, 引入进化策略. 进化操作能寻找优化的粒子, 采样过程会更有效. 为描述后验密度所需要的粒子数可显著减少. 进化策略包含两个操作: 交叉和变异操作直接使用浮点数以避免麻烦的二进制编码和解码. 交叉: 随机选择两个父辈粒子 ($s_t^{(p1)}$, $w_t^{(p1)}$) 和 ($s_t^{(p2)}$, $w_t^{(p2)}$), 计算两个子粒子:

$$\begin{cases} s_i^{(c1)} = \kappa s_i^{(p1)} + (1 - \kappa) s_i^{(p2)} + \tau, w_i^{(c1)} = p(z_i | s_i^{(c1)}) \\ s_i^{(c2)} = \kappa s_i^{(p2)} + (1 - \kappa) s_i^{(p1)} + \tau, w_i^{(c2)} = p(z_i | s_i^{(c2)}) \end{cases} \quad (5)$$

其中 $\kappa \sim U[0, 1]$, $\tau \sim N(0, \Sigma)$, $U[0, 1]$ 是均匀分布, $N(0, \Sigma)$ 是高斯分布. 根据如下标准, 使子粒子 $\{s_i^{(c1)}, s_i^{(c2)}\}$ 代替父粒子 $\{s_i^{(p1)}, s_i^{(p2)}\}$: 如果新粒子 $s_i^{(c1)}$ 满足 $p(z_i | s_i^{(c1)}) > \max(p(z_i | s_i^{(p1)}), p(z_i | s_i^{(p2)}))$ 则被接受, 否则以 $p(z_i | s_i^{(c1)}) / \max(p(z_i | s_i^{(p1)}), p(z_i | s_i^{(p2)}))$ 接受; $s_i^{(c2)}$ 采用相似的接受形式. 变异: 随机选择一个 $(s_i^{(p)}, w_i^{(p)})$, 变异定义为:

$$s_i^{(c)} = s_i^{(p)} + \sigma, w_i^{(c)} = p(z_i | s_i^{(c)}), \sigma \sim N(0, \Sigma) \quad (6)$$

如果新粒子 $s_i^{(c)}$ 满足 $p(z_i | s_i^{(c)}) > p(z_i | s_i^{(p)})$ 则被接受, 否则以 $p(z_i | s_i^{(c)}) / p(z_i | s_i^{(p)})$ 接受. 为改善效率, 交叉操作以概率 p_c 自适应执行, 变异以概率 p_m 自适应执行:

$$p_c = \begin{cases} p_{c1} - \frac{(p_{c1} - p_{c2})(f_c - f_{avg})}{f_{max} - f_{avg}}, & f_c \geq f_{avg} \\ p_{c1}, & f_c < f_{avg} \end{cases} \quad (7)$$

$$p_m = \begin{cases} p_{m1} - \frac{(p_{m1} - p_{m2})(f_{max} - f_m)}{f_{max} - f_{avg}}, & f_m \geq f_{avg} \\ p_{m1}, & f_m < f_{avg} \end{cases}$$

其中 f_{max} 是种群中最大的适应度值, f_{avg} 表示平均适应度值, f_c 表示要交叉的两个个体中较大的适应度值, f_m 要变异个体的适应度值. 本文取 $p_{c1} = 0.85$, $p_{c2} = 0.65$, $p_{m1} = 0.1$, $p_{m2} = 0.001$.

2.2 单目视觉实现

(1) 基于 DD-BBF 的 SIFT 特征匹配: 从图像中生成的 SIFT 特征数量取决于图像大小、纹理及算法参数. 设 E 和 E' 是两个 SIFT 特征集合, $d \in E'$, $d', d'' \in E$, 如果 $|d - d'| / |d - d''| < \alpha$, 则 d 与 d' 是一对匹配点, 其中 α 为匹配阈值, d' 和 d'' 分别是 d 的最/次邻近点. 如果依次计算 E 中点与 d 的欧式距离, 从而找到 d 的最/次邻近点, 算法开销太大. 基于 KD-Tree 的邻近点搜索算法, 可将复杂度降到 $O(\log_2 N)$. 采用 BBF^[9] 算法对基于 KD-Tree 的算法逼近可进一步降低开销. 本文中发现, 采用双向 BBF 匹配即 $\{E \leftarrow E'\} \cap \{\{E \leftarrow E'\} \rightarrow E'\}$, 可在时间少量增加条件下, 去除大多数误匹配, 因为同一对误匹配点, 同时在两个方向中出现的概率比单向中出现的概率要小得多, 即使在发生较大尺度和旋转条件下, 仍取得良好匹配结果.

(2) 三维重建: 如果机器人在 t_1 和 t_2 时刻观察到三维点 $P(x_w, y_w, z_w)$, P 与两时刻的图像坐标 $p_1(u_1, v_1)$ 与 $p_2(u_2, v_2)$ 关系为 $u_i [u_i v_i 1]^T = M_i [x_w y_w z_w 1]^T$, $i = 1, 2$, M_i 是两时刻的投影矩阵. 本文通过离线标定摄像机内参数, 可得投影矩阵, 利用最小二乘法消去 z_{c1} 与 z_{c2} , 获得 P 的三维坐标.

3 位置识别

提出基于 HMM 模型的位置识别算法. 每个位置 L_i

由观测 z_i 和相似度 $p(z_i | L_i = L_i)$ 描述, 最可能的位置由 $P(L_i = L_i | z_{1:t})$ 决定:

$$P(L_i = L_i | z_{1:t}) \propto p(z_t | L_i = L_i) P(L_i = L_i | z_{1:t-1}) \\ = p(z_t | L_i = L_i) \sum_j A(i, j) P(L_{t-1} = L_j | z_{1:t-1}) \quad (8)$$

其中 N 是位置数, $A(i, j)$ 代表位置邻接概率. 假设 $F_t = \{f_1, \dots, f_k\}$ 是在 t 时刻观测到的特征, 其中 n 个与路标匹配: $n_t^i = \{f_1 \sim l_{j1}, \dots, f_n \sim l_{jn}\}$, 有 m 个与 $t-1$ 时观测到的特征匹配, 但没有重建和加入地图库: $n_t^v = \{f_{n+1} \sim v_{jn+1}, \dots, f_{n+m} \sim v_{jn+m}\}$, 则观测 z_t 的相似度为 $p(z_t | L_i^{(i)}, n_t) = p(z_t^i | L_i^{(i)}, n_t^i) p(z_t^v | L_i^{(i)}, n_t^v)$, 其中 z_t^i 代表观测 $F_t = \{f_1, \dots, f_n\}$, z_t^v 代表观测 $F_v = \{f_{n+1}, \dots, f_{n+m}\}$, 这两个相似度分别为:

$$\ln p(z_t^i | L_i^{(i)}) = \sum_{j=1}^n \ln p(f_j | L_i^{(i)}, l_{jj}) \\ \ln p(z_t^v | L_i^{(i)}) = \sum_{j=n+1}^{n+m} \ln p(f_j | L_i^{(i)}, v_{jj}) \quad (9)$$

如果 3D 路标 l_{jj} 为 $(x_w^{(j)}, y_w^{(j)}, z_w^{(j)})$, l_{jj} 的 2D 图像坐标为 $\hat{l}_{jj}(u, v)$, 则 $z_c [u v 1]^T = M [x_w^{(j)} y_w^{(j)} z_w^{(j)} 1]^T$, 这里 M 已知. 如果删除未知变量 z_c , 得到如下观测等式:

$$u = \frac{m_{11} x_w^{(j)} + m_{12} y_w^{(j)} + m_{13} z_w^{(j)} + m_{14}}{m_{31} x_w^{(j)} + m_{32} y_w^{(j)} + m_{33} z_w^{(j)} + m_{34}} \quad (10)$$

$$v = \frac{m_{21} x_w^{(j)} + m_{22} y_w^{(j)} + m_{23} z_w^{(j)} + m_{24}}{m_{31} x_w^{(j)} + m_{32} y_w^{(j)} + m_{33} z_w^{(j)} + m_{34}}$$

其中 m_{ij} 是 M 的第 i 行第 j 列元素. 如果计算得到部分 $x_w^{(j)}, y_w^{(j)}, z_w^{(j)}$, 则可求得观测等式的雅各比矩阵 J , $\ln p(f_j | L_i^{(i)}, l_{jj})$ 可计算如下:

$$\ln p(f_j | L_i^{(i)}, l_{jj}) F = -0.5 \min(T_i, (I_j - I_j)^T S^{-1} (I_j - I_j)) \\ S = J(R_i G_{jj} R_i^T) J^T \quad (11)$$

其中 G_{jj} 是路标 l_{jj} 的协方差, 为防止误观测显著影响观测相似度, 最大观测变化取 $T_i = 3$. 由于 v_{jj} 没有 3D 空间信息, $\ln p(f_j | L_i^{(i)}, v_{jj})$ 仅根据极线约束计算:

$$\ln p(f_j | L_i^{(i)}, v_{jj}) = -0.5 (\text{dist}(I_j, H_{jj}) + \text{dist}(I_j, H_j)) \quad (12)$$

其中 I_j 是 v_{jj} 的图像坐标, H_{jj} 是 t 时刻相对于 v_{jj} 的极线, H_j 是 $t-1$ 时相对于 f_{jj} 的极线, $\text{dist}(\cdot)$ 是距离函数.

4 机器人全局定位与泊位

4.1 全局定位

进行全局定位时, 机器人观测到的特征与地图中的路标进行匹配, 假设获得 k 个匹配对. 由于地图存储了路标每次被机器人观测时的机器人位姿, 因此可获得这 k 个特征在 t_i 时刻被观测到的数目 k_i 及对应图像坐标. 假设 $\{k_1, \dots, k_n\}$ 是前 n 个最大的, 根据相对位姿估计方法, 可用每 t_i 时刻观测到的路标数目 k_i 算出该时刻世界坐标系下可能的摄像头坐标系方向 θ_i 及旋

转矩阵 R_i , 因此共获得 n 个摄像头方向 $\{\theta_1, \dots, \theta_n\}$ 和旋转矩阵 $\{R_1, \dots, R_n\}$. 根据路标特征的三维坐标及通过相对定位确定的方向角 θ_i , 计算机器人的准确位置, 投影方程 $z_i^T [u_i^T v_i^T 1]^T = K [R_i T_i] [x_i^T y_i^T z_i^T]^T$, $(u_i^T, v_i^T, 1)^T$ 与 $(x_i^T, y_i^T, z_i^T, 1)^T$ 是路标特征在当前时刻图像坐标与三维坐标的齐次形式, 如果机器人只在 $x-z$ 平面运动, 所以 $T_i = [x_i, 0, z_i]^T$, 则可得:

$$z_i = \frac{(m_{31}^i x_i' + m_{33}^i z_i') v_i' - a_i v_i'}{(v_0' - v_i')},$$

$$a_i x_i = (m_{31}^i x_i' + m_{33}^i z_i') u_i' - m_{11}^i x_i' - m_{13}^i z_i' - (u_0' - u_i') z_i \quad (13)$$

其中 $m_{ik}^i (i, k \in \{1, 2, 3\})$ 是内部矩阵与旋转矩阵相乘后获得的投影矩阵第 i 行第 k 列元素. 因此 k_i 个路标中的每一个都能计算出一个可能的机器人位姿, 但是路标的三维坐标是通过三维重建获得的, 为了获得可靠的机器人位姿, 采用 RANSAC 方法, 每次从 k_i 个路标中随机抽取两个路标并用最小二乘法求解四个方程得到稳定解 z_i 和 x_i , 重复抽取 H 次, 得到 H 个可能的机器人位姿. 由于每个时间步 t_i 都可获得 H 个可能位姿, 则共获得 nH 可能位姿. 从中选出最可靠结果: 假设与当前图像匹配的 $N = \sum_{i=1}^n k_i$ 个路标 $\{I^{(1)} \sim L^{(1)}, \dots, I^{(N)} \sim L^{(N)}\}$, 根据针孔模型, 路标 $L^{(i)}$ 在当前图像的投影为 $I'^{(i)}(u', v')$, 如果与对应特征 $I(i)(u, v)$ 满足 $|u' - u| < \Delta_u$ 并且 $|v' - v| < \Delta_v$, 则为投影矩阵对应的位姿投一票, 得票最多者胜出.

4.2 机器人泊位

在位置识别和全局定位基层上, 根据与期望位姿的差别, 可采用极坐标差控制泊位: 即如果当前与期望位姿之间相对量为极坐标 (ρ, θ) , 选择动作 $A(\{\text{转动} | \theta| > \epsilon; \text{前进} | \theta| < \epsilon \text{ 且 } |\rho| > \kappa; \text{停止} | \theta| < \epsilon \text{ 且 } |\rho| < \kappa\})$, ϵ 和 κ 是预设值, 进行迭代控制, 可使机器人逐渐运动到期望位姿. 为了提高泊位精度, 提出极点伺服方法:

假设机器人当前位姿和期望位姿在运动平面内的投影如图 1 所示, O_{ca} 与 O_{cd} 为摄像头镜头光心, 基线 $O_{ca} O_{cd}$ 与两成像面交点 $e_a = (e_{au} e_{av})^T$, $e_d = (e_{du} e_{dv})^T$ 为极点. 根据极线几何理论, 当 e_{au} 和 e_{du} 同时变化到 0 时, 机器人与期望位姿实现准直 (即 $O_{ca} O_{ia}$ 与 $O_{cd} O_{id}$ 重合). 根据此原理建立极点伺服方法. 根据图

1, $y = x \tan \psi$, $y = d \sin \psi$, $x = d \cos \psi$. 又因为 $f = e_{du} \tan \psi$, $e_{du} = fx/y$, $e_{au} = f \frac{x \sin \theta - y \cos \theta}{x \cos \theta + y \sin \theta}$. 机器人微分运动学模型: $\dot{x} = \mu \cos \theta$, $\dot{y} = \mu \sin \theta$, $\dot{\theta} = \omega$, 其中 μ




图1 计算极点运动学的平面几何关系

和 ω 是平移速度和角速度. 对时间求导得到 $\dot{e}_{du} = \mu f \frac{\sin(\psi - \theta)}{d \sin^2 \psi}$, 由 $y = x \tan \psi$ 得到 $\dot{e}_{au} = \mu \frac{f \sin(\psi - \theta)}{d \cos^2(\psi - \theta)} + \omega \frac{f}{\cos^2(\psi - \theta)}$, 又因为 $\sin(\psi - \theta) = \frac{se_{au}}{\sqrt{e_{au}^2 + f^2}}$, $\cos(\psi - \theta) = \frac{f}{\sqrt{e_{au}^2 + f^2}}$, 其中 s 是符号函数, 消去角度变量后得到:

$$\begin{bmatrix} \dot{\mu} \\ \dot{\omega} \end{bmatrix} = \begin{bmatrix} 0 & \frac{-sfd \sqrt{e_{au}^2 + f^2}}{e_{au}(e_{du}^2 + f^2)} \\ \frac{f}{e_{au}^2 + f^2} & -\frac{f}{e_{du}^2 + f^2} \end{bmatrix} \begin{bmatrix} -k_1 e_{au} \\ -k_2 e_{du}^{\beta/\alpha} \end{bmatrix} \quad (14)$$

其中 d 可用一个估算值 d' 代替, 这不影响收敛性, 控制参数取 $k_1 = 0.08$, $k_2 = 1$, $\beta/\alpha = 7/9$ 影响运动轨迹和收敛速度. 当机器人实现准直后, 机器人沿着光轴向目标运动. 如果当前与目标图像间的匹配点的均方误差达到设定阈值, 泊位完毕.

5 实验结果

实验使用 Pioneer 3-DX 移动机器人如图 2 左图所示. 单目摄像机分辨率 320×240 . 实验环境如图 2 右图所示. 机器人放置在距墙 2m, CCD 朝向墙, 运动方向与墙平行. 当机器人向前运动, 采集并处理沿路图像, 建立三维特征地图. 图 3 是创建的部分三维全局 SIFT 路标.

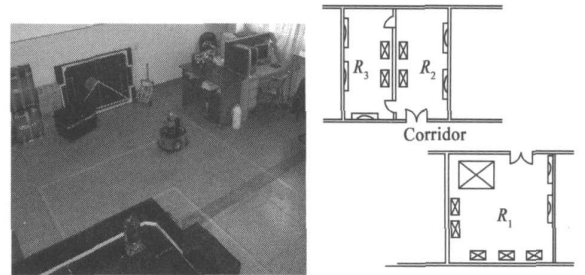


图2 移动机器人与实验环境




图3 从图像序列创建的部分3D路标

图 4 是本文改进的与传统 RBPF 的详细的比较. 从图中可见, 传统 RBPF 通过增加粒子数目, 能极大改善性能, 然而其需求的存储和计算负担也会激增. 本文改进的 RBPF 由于采用进化策略, 大部分粒子能汇聚到高

权重区域, 以较少的粒子近似了后验; 引入进化策略本身所增加的计算负担不及减少粒子数所降低的计算负担, 即改进的 RBPF 以较少的粒子、较低的计算负担获得更高的机器人定位精度和路标定位精度(即地图精度), 也说明有效防止了粒子退化和早熟.

机器人创建的地图(鸟瞰图)如图 5 所示, 地图中的点代表 SIFT 路标, 也代表了物体的占位. 选择 14 个位置来测试全局定位及泊位. 全局定位是以“诱拐”方式把机器人放置到如图 5 所示的 14 个位置. 每个点进行 20 次实验, 分别从 x , y 和方向角 θ 进行了误差概率分析, 如图 6 所示. 算法的估计结果与实测的平均平移误差在 10cm 以内, 平均旋转误差在 3° 以内. 因此本文方法是可靠的. 全局定位实验中, 记录这 14 个位置的位姿 s_j 和图像 I_j , 生成集合 $P_j < s_j, I_j >$ ($j=1, \dots, 14$).




图5 环境地图和泊位路径

泊位实验以 P_j 为输入, 机器人按照位置序号, 从起点依次泊位到这 14 个位置, 泊位是否成功, 根据 P_j 中 I_j 与泊位过程图像之间的匹配点的位置均方误差来判断. 机器人先进行位置识别和全局定位, 然后根据当前




图6 定位误差分析

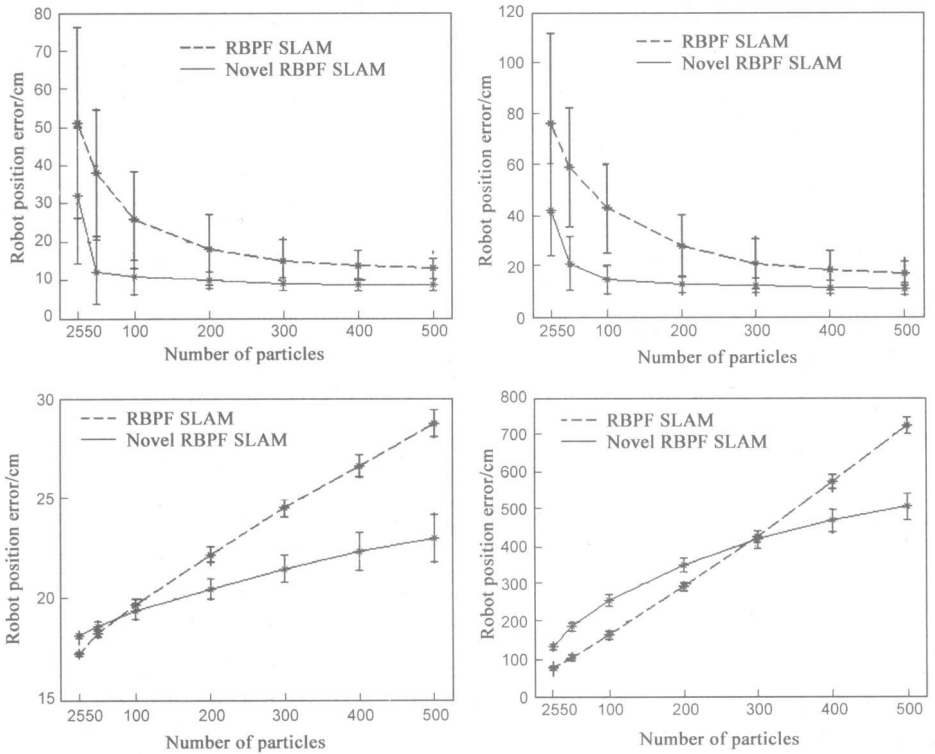


图4 改进的与传统RBPF的比较

位姿与 P_j 中 I_j 的位姿差别, 进行泊位, 泊位路径如图 5 所示. 在 20 次实验中, 泊位成功率达到 90%. 其成功率依赖于位置识别方法的鲁棒性、相对姿态估算的鲁棒性, 也依赖路径上 SIFT 路标的数量. 泊位失败主要发生在路标少或易混淆的位置. 定量的位置识别性能如图 7 所示. 当机器人从起点 (Start) 运动到目标点 (End), 位置正确识别率为 97.9% (140/143), 误识别主要发生在特征少和易混淆位置.




图7 位置识别结果

另外测试了极点伺服方法的性能, 机器人初始位姿靠近导航路径, 并且方向与期望路径相近. 结果在大部分情况下, 机器人位姿成功收敛到目标位置. 错误的泊位主要来自错误的位置识别. 收敛速度取决于伺服控制参数和机器人初始位姿. 图 8 是在没有及两个障碍物条件下伺服运动轨迹. 定量的泊位精度为平移误差小于 6cm, 角度误差小于 2° , 优于全局定位精度.




图8 极点伺服轨迹

6 结论


本文提出基于单目视觉的移动机器人室内全局定位和泊位方法, 采用改进的 RBPF 方法以较少的粒子、较低的计算负担获得更高的机器人定位精度和地图精度, 有效防止了粒子退化和早熟; 在特征地图的框架下解决了定位和泊位问题。在真实室内环境下的实验结果证实了该方法的优良性能。

参考文献:

- [1] R S Gm, P J Hoon, L Y Hoon, S Y Kouk. Flexible docking mechanism with error-compensation capability for auto recharging system of mobile robot[J]. International Journal of Control, Automation and Systems, 2008, 6(5): 731—739.
- [2] Ashkaraj Immanuel A R, Silson, Peter M G, Tsourdos. Robust sensor-based navigation for mobile robots[J]. IEEE Transactions on Instrumentation and Measurement, 2009, 58(3): 551—556.
- [3] González J, Blanco J L, Galindo C, Ortiz-de-Galisteo A. Mobile robot localization based on ultra-wide-band ranging: A particle filter approach[J]. Robotics and Autonomous Systems, 2009, 57(5): 496—507.
- [4] 高庆吉, 雷亚莉, 胡丹丹. 基于自适应感知复位算法的移动机器人定位[J]. 电子学报, 2007, 35(11): 2166—2171. GAO Qing-ji, LEI Ya-li, HU Dan-dan. A robot localization method based on adaptive sensor resetting algorithm[J]. Acta Electronica Sinica, 2007, 35(11): 2166—2171. (in Chinese)

- [5] Grzonka Slawomir, Plagemann Christian, Grisetti Giorgio. Look-ahead proposals for robust grid-based SLAM with rao-blackwellized particle filters[J]. International Journal of Robotics Research, 2009, 28(2): 191—200.
- [6] Blanc G, Mezouar Y, Martinet P. Indoor navigation of a wheeled mobile robot along visual routes[A]. Proceedings of the IEEE International Conference on Robotics and Automation[C]. Spain: IEEE, 2005. 3365—3370.
- [7] Gian Luca Mariottini, Giuseppe Oriolo. Image-based visual servoing for nonholonomic mobile robots with central catadioptric camera[A]. Proc IEEE Int Conf Robot Autom[C]. Orlando, Florida: IEEE, 2006. 497—503.
- [8] Sunhyo Kim, Se-Young Oh. Hybrid position and image based visual servoing for mobile robots[J]. Journal of Intelligent & Fuzzy Systems 2008, 18: 73—82.
- [9] Lowe D G. Distinctive image features from scale-invariant keypoints[J]. Int J of Computer Vision, 2004, 60(2): 91—110.

作者简介:



陈凤东 男, 1977 年生于吉林省通化县, 哈尔滨工业大学电气学院讲师, 博士, 主要研究方向为视觉检测与智能机器人。
E-mail: chenfd@hit.edu.cn



洪炳霖 男, 1937 年生, 哈尔滨工业大学教授, 博士生导师, 主要研究方向为分多智能体机器人系统。